НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»»

Факультет Информационных технологий

Направление подготовки:	09.03.02 Информационные системы и технологии	**Кафедра**	ИИиАД
(код, наименование)		*(аббревиатура)*	

Профиль: Разработка, сопровождение и обеспечение безопасности информационных систем

РЕШЕНИЕ КЕЙСА № 1

по дисциплине «Искусственный интеллект, большие данные и этика»

на тему **Беспристрастный HR: дискриминация в автоматическом скрининге резюме**

Обучающийся ***Шатов Илья Андреевич***

(Фамилия Имя Отчество) *(подпись)*

Группа ***ДМЭ-101цэии***

Преподаватель

(Фамилия Имя Отчество) *(подпись)*

МОСКВА 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....3
1 Механизм воспроизведения дискриминации моделью при нейтральных признаках.....4
2 Распределение ответственности за дискриминационные решения системы.6
3 Меры по устранению смещения и предупреждению дискриминации.....9
ВЫВОДЫ.....11
СПИСОК ИСТОЧНИКОВ.....12

ВВЕДЕНИЕ

Автоматический скрининг резюме стал массовой практикой крупного найма: модели машинного обучения ранжируют кандидатов до первого контакта с рекрутером. Этическая привлекательность автоматизации основана на ожидании беспристрастности — алгоритм «не устаёт», «не предвзят» и «не видит» пола и возраста, если эти признаки исключены из данных.

Ситуация кейса опровергает это ожидание. Модель, обученная на исторических «успешных наймах» компании, систематически занижает рейтинг женщин с перерывами в стаже и кандидатов старше 45 лет, хотя прямые признаки пола и возраста в неё не подавались. Отбор выполняется автоматически, без участия человека, значит дискриминационный эффект воспроизводится в каждом решении.

Цель работы — объяснить механизм возникновения смещения при формально нейтральных признаках, определить круг ответственных за дискриминационные решения и предложить комплекс мер по устранению смещения. Задачи соответствуют пунктам задания кейса и раскрыты в разделах 1–3.

1 Механизм воспроизведения дискриминации моделью при нейтральных признаках

Условие. Объясните, почему модель воспроизводит и усиливает историческую дискриминацию, если прямые признаки пола и возраста исключены. Опишите механизм возникновения смещения (proxy-признаки, смещённая обучающая выборка, обратная связь).

Модель машинного обучения не «оценивает заслуги» кандидата — она минимизирует ошибку предсказания целевой переменной на обучающей выборке. Целевой переменной здесь выступает исторический факт «успешного найма», то есть решения прошлых нанимающих менеджеров. Если эти решения в прошлом принимались с уклоном против женщин с перерывами в стаже и кандидатов старшего возраста, то именно этот уклон зафиксирован в данных как «паттерн успеха». Модель не придумала предвзятость — она воспроизвела статистическую закономерность исторической кадровой политики компании.

Исключение прямых признаков («пол», «возраст», «дата рождения») не устраняет дискриминацию, потому что в данных существуют прокси-признаки (proxy variables) — корреляты защищённых характеристик. Перерывы в стаже типично связаны с декретными отпусками; формулировки обязанностей и грамматический род глаголов прошлого времени в резюме маркируют пол; год выпуска из учебного заведения почти прямо указывает на возрастную группу. Статистический алгоритм обязан «найти» наиболее информативные комбинации таких признаков — это его функция, а не дефект.

Таблица 1 — Источники смещения, механизм их действия и контрмеры

Источник смещения	Механизм действия	Контрмера
Смещённая историческая выборка	«Успешные наймы» отражают прошлую кадровую политику; модель копирует уклон как «закономерность успеха»	Переопределить целевую переменную по объективным критериям результативности; переобучить на аудированных данных

Proxy-признаки (перерывы стажа, формулировки, год выпуска)	Признаки коррелируют с полом и возрастом и служат модельной «заменой» исключённых признаков	Аудит признаков на проксикорреляцию; удаление или преобразование прокси-признаков
Обратная связь (feedback loop)	Отобранные моделью сотрудники становятся будущей обучающей выборкой; смещение усиливается с каждым циклом найма	Разрыв петли: обязательная человеческая проверка отклонённых, мониторинг распределения решений
Нерепрезентативность выборки	Отдельные группы представлены слабо, ошибки модели для них выше	Дозбор данных по недопредставленным группам; оценка качества по группам

Сводный механизм показан в таблице 1: смещение попадает в модель через обучающую выборку (таблица 1, строка 1), закрепляется через прокси-признаки (строка 2) и самоусиливается через обратную связь отбора (строка 3). Особенно опасен контур обратной связи: кандидат, отклонённый моделью, никогда не попадает в историю «успешных наймов», поэтому будущие переобучения воспринимают отклонение как подтверждённую закономерность. Дискриминация перестаёт быть разовой ошибкой и становится самоподдерживающимся процессом.

Вывод: модель воспроизводит историческую дискриминацию, потому что обучалась на смещённых решениях о найме и воссоздала их через прокси-признаки пола и возраста; автоматический контур отбора замыкает обратную связь и усиливает смещение с каждым циклом. Исключение прямых признаков — необходимое, но недостаточное условие беспристрастности.

2 Распределение ответственности за дискриминационные решения системы

Условие. Определите круг ответственных за произошедшее: работодатель, разработчики системы, HR-директор, сама система. Обоснуйте распределение моральной и юридической ответственности; ответьте, может ли ИИ быть субъектом ответственности, и каким должно быть участие человека в решениях о найме.

Ответственность за дискриминационные решения системы распределяется между организационными субъектами по характеру их вклада и степени контроля над риском. Ни один алгоритм субъектом права не является: нейросеть не обладает волей, интересами и имущественной обособленностью, не может быть стороной трудовых и деликтных отношений, поэтому ответственность не может быть делегирована «машине». Формула «так решил алгоритм» юридически несостоятельна — решение всегда принадлежит работодателю, использующему инструмент.

Юридическая основа ответственности работодателя — запрет дискриминации в сфере труда: статьёй 3 Трудового кодекса РФ запрещено ограничение прав независимо от пола, возраста и других обстоятельств, не связанных с деловыми качествами работника; статья 64 запрещает необоснованный отказ в заключении трудового договора. Работодатель как оператор системы отвечает за любой отбор, выполненный от его имени, включая автоматический. Для систем найма это требование закреплено и наднационально: Искусственный интеллектуальный акт ЕС (Регламент (ЕС) 2024/1689) относит системы найма к высокому риску и обязывает провайдеров и эксплуатантов к управлению рисками, тестированию и человеческому надзору.

– Работодатель (компания) — несёт основную юридическую ответственность перед кандидатами: именно перед ним возникают

трудоправовые последствия дискриминационного отказа; он выбрал систему, ввёл её в эксплуатацию и получал выгоду от её работы.

– Разработчики системы — ответственны за качество и безопасность продукта: полноту тестов на смещение, документирование ограничений модели, предупреждение заказчика о недопустимости полностью автоматического применения.

– HR-директор — ответственный за внедрение: принял решение об эксплуатации без пилотной валидации, регулярного аудита и мониторинга; его вина — организационная и профессиональная.

– Нейросеть — не субъект права; её «поведение» есть материализованные решения людей: выбор данных, архитектуры, метрик качества и порядка применения.

Моральная ответственность соответствует юридической, но шире по содержанию: каждая из сторон контроля должна была предвидеть риск косвенной дискриминации — этот риск хорошо известен и описан в литературе о справедливости машинного обучения. Ответственность разработчика не поглощается ответственностью заказчика: продать систему найма без тестов на смещение — профессиональная небрежность. Ответственность HR-директора также самостоятельна: внедрение средства, принимающего решения о людях, без человеческой проверки — прямое нарушение профессионального долга.

Отсюда следует нормативное требование к участию человека (human-in-the-loop): решение, существенно влияющее на права и трудовую судьбу кандидата, должно приниматься человеком, оснащённым, а не заменённым алгоритмом. Регламент (ЕС) 2016/679 (GDPR) в статье 22 прямо ограничивает решения, основанные исключительно на автоматизированной обработке; отнесение кандидата к «отклонённым» без содержательного человеческого рассмотрения таким решением и является. Человеческая

проверка должна быть действенной: проверяющий должен видеть обоснование рейтинга и иметь полномочия изменить результат.

Вывод: субъектом ответственности является работодатель как оператор системы; самостоятельная ответственность лежит на разработчиках (аудит и тесты на смещение) и на HR-директоре (внедрение без валидации и мониторинга); нейросеть субъектом права не является. Обязательный элемент законного отбора — действующий human-in-the-loop при принятии решения о кандидате.

3 Меры по устранению смещения и предупреждению дискриминации

Условие. Предложите комплекс мер по устранению дискриминации: работа с признаками и данными, методы debiasing, метрики справедливости, организационные процедуры (аудит, участие человека, прозрачность отказа кандидату).

Устранение смещения ведётся на трёх уровнях: данные и признаки, обучение модели, организационный контур эксплуатации. На уровне данных выполняется аудит признаков на проксикорреляцию с защищёнными характеристиками: перерывы стажа переосмысляются как нейтральный факт, формулировки резюме нормализуются, год выпуска исключается в пользу стажа «после последней роли». На уровне обучения применяются методы debiasing: перевзвешивание примеров (reweighing), adversarial debiasing (обучение предсказателя с одновременным подавлением способности восстановить защищённый признак), пороговая калибровка по группам.

Методы debiasing не принимаются «на веру» — они контролируются метриками справедливости на отложенных выборках с известной защитной принадлежностью (используемой только для контроля, не для отбора). Основные метрики приведены в таблице 2; устойчивая система мониторинга отслеживает их по группам и по времени.

Таблица 2 — Метрики справедливости и их назначение

Метрика	Требование	Что фиксирует
Demographic parity	Доля положительных решений одинакова по группам	Равенство исходов отбора (доступа к следующему этапу)
Equalized odds	Равные вероятности ошибки первого и второго рода по группам	Равенство качества модели для групп: одинаково частая ошибочная отбраковка достойных кандидатов
Equal opportunity	Равные вероятности истинно положительного решения	Равный шанс «пройти дальше» при реальной квалификации
Calibration by group	Равная калибровка рейтинга по группам	Одинаковая интерпретируемость

		рейтинга независимо от группы

Организационный контур делает технические меры устойчивыми (таблица 1, строка 3). Минимальный набор процедур: регулярный независимый аудит справедливости (до внедрения и периодически); обязательная человеческая проверка всех отклонённых кандидатов; запрет полностью автоматического отказа; логирование решений с основаниями; право кандидата на содержательное объяснение отказа и на пересмотр человеком; публичная модельная карта (model card) с описанием назначения, ограничений и результатов проверки справедливости.

– аудит и очистка признаков: удаление/преобразование прокси-признаков, контроль корреляций с защищёнными характеристиками;

– переобучение на объективной целевой переменной и аудированных данных; дозбор по недопредставленным группам;

– debiasing: перевзвешивание, adversarial debiasing, пороговая калибровка по группам;

– контроль метрик справедливости (таблица 2) на отложенных выборках и в эксплуатации;

– обязательный human-in-the-loop: человек проверяет отклонённых и утверждает отказы;

– регулярный аудит, логирование, объяснение причин отказа кандидату, model card.

Вывод: дискриминация устраняется сочетанием технических мер (работа с данными, debiasing, метрики справедливости из таблицы 2) и организационных процедур (регулярный аудит, обязательная человеческая проверка отклонённых, прозрачность отказа). Разрыв контура обратной связи — приоритетная мера: без него любое переобучение воспроизводит смещение.

ВЫВОДЫ

В пункте (a) показано: модель дискриминирует не вопреки «нейтральным» признакам, а благодаря прокси-признакам и смещённой обучающей выборке; автоматический отбор замыкает обратную связь, из-за которой историческая предвзятость компании воспроизводится и усиливается.

В пункте (b) определено распределение ответственности: юридически отвечает работодатель как оператор системы; разработчики отвечают за аудит и тесты на смещение, HR-директор — за внедрение без валидации и мониторинга; нейросеть субъектом права не является. Законный отбор требует действующего human-in-the-loop (ст. 3 и 64 ТК РФ, ст. 22 GDPR, высокий риск по Регламенту (ЕС) 2024/1689).

В пункте (c) предложен комплекс мер: аудит и очистка прокси-признаков, переобучение на объективной целевой переменной, debiasing (перевзвешивание, adversarial debiasing), контроль метрик справедливости (таблица 2), регулярный аудит, человеческая проверка отклонённых кандидатов и прозрачное объяснение причин отказа.

Общий вывод кейса: «беспристрастность» алгоритма — свойство не кода, а всей системы найма: данных, метрик, процедур проверки и распределения ответственности. Без организационного контура справедливости автоматизация не уменьшает, а масштабирует историческую дискриминацию.

СПИСОК ИСТОЧНИКОВ

1. Трудовой кодекс Российской Федерации от 30.12.2001 № 197-ФЗ (ст. 3, 64) // СПС «КонсультантПлюс». — Текст : электронный.

2. Регламент (ЕС) 2016/679 Европейского парламента и Совета от 27 апреля 2016 г. «О защите физических лиц при обработке персональных данных и о свободном обращении таких данных» (General Data Protection Regulation, ст. 22) // EUR-Lex : [сайт]. — URL: https://eur-lex.europa.eu/eli/reg/2016/679/oj (дата обращения: 27.10.2026). — Текст : электронный.

3. Регламент (ЕС) 2024/1689 Европейского парламента и Совета от 13 июня 2024 г., устанавливающий гармонизированные правила в области искусственного интеллекта (Artificial Intelligence Act) // EUR-Lex : [сайт]. — URL: https://eur-lex.europa.eu/eli/reg/2024/1689/oj (дата обращения: 27.10.2026). — Текст : электронный.

4. NIST AI Risk Management Framework (AI RMF 1.0) / National Institute of Standards and Technology. — Gaithersburg, 2023. — URL: https://doi.org/10.6028/NIST.AI.100-1 (дата обращения: 27.10.2026).

5. ГОСТ Р 59276-2020. Системы искусственного интеллекта. Способы обеспечения доверия. Общие положения. — Москва : Стандартинформ, 2020.

6. Mehrabi, N. A Survey on Bias and Fairness in Machine Learning / N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman, A. Galstyan // ACM Computing Surveys. — 2021. — Vol. 54, № 6. — Article 115. — DOI 10.1145/3457607.