НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»»

Факультет Информационных технологий

Направление подготовки:	09.03.02 Информационные системы и технологии	**Кафедра**	ИИиАД
(код, наименование)		*(аббревиатура)*	

Профиль: Разработка, сопровождение и обеспечение безопасности информационных систем

РЕШЕНИЕ КЕЙСА № 2

по дисциплине «Искусственный интеллект, большие данные и этика»

на тему **Умный медицинский ассистент на основе LLM: границы доверия и ответственность**

Обучающийся ***Шатов Илья Андреевич***

(Фамилия Имя Отчество) *(подпись)*

Группа ***ДМЭ-101цэии***

Преподаватель

(Фамилия Имя Отчество) *(подпись)*

МОСКВА 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....3
1 Вероятностная природа LLM и этические границы применения в медицине 4
2 Система ограждений (guardrails) и декларативных ограничений ассистента6
3 Распределение ответственности между участниками внедрения.....8
ВЫВОДЫ.....10
СПИСОК ИСТОЧНИКОВ.....11

ВВЕДЕНИЕ

Большие языковые модели (LLM) активно внедряются в здравоохранение: чат-ассистенты отвечают пациентам, подсказывают препараты и режим. Экономическая привлекательность решения очевидна, однако цена ошибки в медицине — здоровье и жизнь пациента, поэтому стандарт «работает в большинстве случаев» здесь неприемлем.

Ситуация кейса: ассистент стартапа в частной клинике подбирает безрецептурные препараты по жалобам пациента; база знаний не редактировалась профильным врачом; в тестах модель уверенно рекомендовала противопоказанные препараты и однажды проигнорировала упоминание аллергии. Руководство предлагает подключить ассистента к медкартам, врач пилота сомневается.

Цель работы — определить допустимую роль LLM-ассистента в медицинском контуре, спроектировать систему технических и организационных ограждений и распределить ответственность между участниками внедрения. Задачи соответствуют пунктам задания и раскрыты в разделах 1–3.

1 Вероятностная природа LLM и этические границы применения в медицине

Условие. Объясните, почему выходные данные LLM принципиально нельзя считать медицинским заключением: вероятностная природа генерации, галлюцинации, правдоподобие vs истинность. Какие этические принципы требуют ограничить роль ассистента?

LLM генерирует текст вероятностно: на каждом шаге модель выбирает продолжение, наиболее правдоподобное по статистическим закономерностям обучающего корпуса. Правдоподобие и истинность — разные свойства: фраза может быть типичной для медицинских текстов и при этом ложной конкретно для данного пациента. Модель не обращается к проверенной базе знаний и не «знает» факт — она строит правдоподобную форму ответа.

Из вероятностной природы следует неустранимость галлюцинаций на уровне самой архитектуры: генеративная модель способна сконструировать несуществующее взаимодействие препаратов или проигнорировать критический факт (аллергия), если статистический контекст этого «не требует». Уверенность формулировки не отражает вероятность истинности: особенно опасны уверенные ложные ответы. В медицине такой режим ошибок недопустим: пациент строит решения о своём здоровье на тексте ассистента, а «уверенная» ложь воспринимается как заключение специалиста.

Этическая оценка опирается на классические принципы биомедицинской этики (Beauchamp, Childress): beneficence (благо пациента), non-maleficence («не навреди»), автономия и справедливость. Принцип non-maleficence прямо запрещает использовать инструмент с известным и неустранимым классом ошибок там, где ошибка причиняет вред. Дополняет его принцип предосторожности: при риске непоправимого вреда бремя доказательства безопасности лежит на внедряющем, а не на сомневающемся. Отсюда нормативная граница роли: ассистент может быть информатором и

навигатором (объяснить, напомнить, направить к врачу), но не диагностом и не назначающим субъектом. Всемирная организация здравоохранения в руководстве по этике ИИ в здравоохранении требует человеческого надзора и прозрачности ограничений систем ИИ.

Вывод: выход LLM принципиально не является медицинским заключением: генерация вероятностна, галлюцинации не устранимы архитектурно, правдоподобие не равно истинности. Принципы non-maleficence и предосторожности требуют роль «информатор, не диагност»: доверять ассистенту жизнь пациента без программного контура безопасности нельзя.

2 Система ограждений (guardrails) и декларативных ограничений ассистента

Условие. Спроектируйте набор технических и организационных ограждений (guardrails) и декларативных ограничений: обязательная проверка аллергий и взаимодействий по медкарте, программный фильтр противопоказаний, эскалация «красных флагов» к врачу, дисклеймеры, логирование и аудит, тестирование на устойчивость, ответственность за базу знаний.

Ключевой принцип проектирования — разделение слоёв: LLM отвечает только за диалог и формулировки; все решения, связанные с безопасностью, выполняет детерминированный программный контур. Проверка аллергий и взаимодействий — не задача языковой модели, а вызов программного фильтра по нормативному справочнику: аллергии читаются из медкарты обязательно (подключение к медкарте оправдано именно этим), и совпадение «препарат — противопоказание/аллергия» блокирует рекомендацию до её генерации. Подключение медкарты одновременно повышает требования к защите данных: здоровье — специальная категория персональных данных (ст. 10 закона № 152-ФЗ, ст. 9 GDPR).

Таблица 1 — Реестр ограждений (guardrails) ассистента

Ограждение	Слой	Содержание
Обязательное чтение аллергий из медкарты	Данные	Рекомендация невозможна без актуального профиля аллергий; конфликт блокирует ответ
Программный фильтр аллергий и взаимодействий	Правила	Детерминированная проверка по справочнику OTC-препаратов и взаимодействий; не выполняется LLM
Эскалация «красных флагов»	Правила	Симптомы тревожного списка (боль в груди, кровотечения, неврологические знаки) — прямой маршрут к врачу, никаких рекомендаций
Белый список тем и препаратов	Правила	Ассистент ограничен безрецептурным перечнем

		и общим уходом; вне перечня — совет обратиться к врачу
Дисклеймер «не медицинская консультация»	Интерфейс	Каждая сессия маркирована; не заменяет осмотр и назначение врача
Логирование и аудит	Процессы	Полная запись диалогов и решений фильтров; периодический клинический аудит выборки
Fail-safe поведение	Архитектура	При неопределённости, ошибке интеграции или низкой уверенности — эскалация к человеку, а не «лучший guess»
Adversarial-тестирование	Процессы	Регулярные пробы на обход ограждений и редкие клинические сценарии; регресс-набор инцидентов
Врач-редактор базы знаний	Процессы	Персональная ответственность врача за содержимое базы и её версии; обновление по регламенту

Реестр ограждений приведён в таблице 1: данные (строка 1), детерминированные правила (строки 2–4), интерфейс, архитектура и процессы (строки 5–9). Существенно, что каждое ограждение проверяемо: фильтр противопоказаний тестируется юнит-тестами, эскалация — сценариевыми прогонами, аудит — выборочной экспертизой. Декларативная часть — явные ограничения продукта: перечисление неподдерживаемых сценариев, обязательные дисклеймеры, запрет формулировок «диагноз» и «назначение» в ответах ассистента.

Вывод: безопасная конфигурация строится по схеме «LLM — только диалог, безопасность — программный контур»: обязательное чтение аллергий из медкарты, детерминированный фильтр противопоказаний и взаимодействий, эскалация красных флагов, дисклеймеры, логирование, adversarial-тестирование и врач-редактор базы знаний (таблица 1).

3 Распределение ответственности между участниками внедрения

Условие. Распределите ответственность между разработчиками LLM, стартапом (владельцем продукта), врачом, одобрившим внедрение, и клиникой. Обоснуйте долю каждой стороны и необходимые договорные и организационные гарантии.

Ответственность распределяется по способности каждой стороны предвидеть и контролировать соответствующий риск. Разработчики LLM отвечают за модель как таковую: документирование ограничений, корректность предупреждений о галлюцинациях, непредставление модели как медицинского изделия. Они не контролируют конкретное применение и потому не отвечают за клиническую конфигурацию продукта. Основная доля ответственности лежит на стартапе: он принял решения о назначении продукта, составе базы знаний, контуре безопасности и маркетинговых заявлениях; клиническая валидация и защита данных — его прямые обязанности производителя.

Врач, одобривший пилот, несёт профессиональную ответственность за протоколы: подпись врача придаёт продукту клинический статус, поэтому он обязан был удостовериться в наличии фильтров безопасности, клиническом аудите и границах применения. Клиника отвечает за процесс: лицензионность медицинской деятельности, порядок эксплуатации ассистента персоналом, информирование пациентов, сохранение медицинской тайны. Матрица ответственности приведена в таблице 2.

Таблица 2 — Матрица ответственности сторон внедрения

Сторона	Зона ответственности	Обоснование доли
Разработчики LLM	Документированные ограничения модели; предупреждения о галлюцинациях; недопущение позиционирования как медицинского изделия	Контролируют модель, но не конкретное применение
Стартап (владелец	Назначение продукта; база	Принимает все

продукта)	знаний; guardrails; клиническая валидация; защита персональных данных; договоры	продуктовые решения и получает выгоду; основная доля
Врач, одобривший внедрение	Протоколы применения; подтверждение контура безопасности; клинический аудит	Профессиональная ответственность за придание клинического статуса
Клиника	Лицензионность деятельности; регламент работы персонала с ассистентом; информирование пациентов; медицинская тайна	Эксплуатация и организация процесса на своей территории

– договорные гарантии: гарантии качества и компенсации в договоре клиника–стартап; запрет автоматических решений без врача; аудит логов сторонами;

– организационные гарантии: назначенный врач-редактор базы знаний; регламент эскалации; обучение персонала; периодический клинический аудит;

– защита данных: основания обработки данных здоровья, явное согласие пациентов, минимизация и шифрование, оценка воздействия на защиту данных.

Вывод: ответственность распределяется по контролю над риском: разработчики LLM — за документированные ограничения модели; стартап — основная доля (продукт, валидация, персональные данные); врач — профессиональная ответственность за протоколы; клиника — за процесс и лицензионность деятельности (таблица 2). Договорные и организационные гарантии закрепляют эту матрицу на практике.

ВЫВОДЫ

В пункте (a) показано: LLM вероятностен, галлюцинации не устранимы архитектурно, правдоподобие не равно истинности; принципы non-maleficence и предосторожности допускают только роль «информатор, не диагност» — доверять модели решение о жизни пациента без программного контура безопасности нельзя.

В пункте (b) спроектирован реестр ограждений (таблица 1): обязательное чтение аллергий из медкарты, детерминированный фильтр аллергий и взаимодействий по белому списку OTC-препаратов, эскалация «красных флагов» к врачу, дисклеймер «не медицинская консультация», логирование и аудит, fail-safe поведение, adversarial-тестирование и врач-редактор базы знаний.

В пункте (c) определена матрица ответственности (таблица 2): разработчики LLM — за документированные ограничения модели; стартап — основная доля (продукт, клиническая валидация, персональные данные); врач — профессиональная ответственность за протоколы; клиника — за процесс и лицензионность медицинской деятельности.

Общий вывод кейса: LLM-ассистент в клинике допустим как вспомогательный информационный сервис внутри программного контура безопасности и человеческого надзора; попытка использовать его как автономного «диагноста» противоречит и природе технологии, и биомедицинской этике.

СПИСОК ИСТОЧНИКОВ

1. Beauchamp, T. L. Principles of Biomedical Ethics / T. L. Beauchamp, J. F. Childress. — 9th ed. — New York : Oxford University Press, 2019.
2. Федеральный закон от 27.07.2006 № 152-ФЗ «О персональных данных» (ст. 10 — специальные категории персональных данных) // СПС «КонсультантПлюс». — Текст : электронный.
3. Регламент (ЕС) 2016/679 Европейского парламента и Совета от 27 апреля 2016 г. (General Data Protection Regulation, ст. 9) // EUR-Lex : [сайт]. — URL: https://eur-lex.europa.eu/eli/reg/2016/679/oj (дата обращения: 27.10.2026). — Текст : электронный.
4. Ethics and governance of artificial intelligence for health: WHO guidance / World Health Organization. — Geneva : WHO, 2021. — URL: https://www.who.int/publications/i/item/9789240029200 (дата обращения: 27.10.2026).
5. ГОСТ Р 59276-2020. Системы искусственного интеллекта. Способы обеспечения доверия. Общие положения. — Москва : Стандартинформ, 2020.
6. Регламент (ЕС) 2024/1689 Европейского парламента и Совета от 13 июня 2024 г. (Artificial Intelligence Act: системы высокого риска, включая медицинские изделия) // EUR-Lex : [сайт]. — URL: https://eur-lex.europa.eu/eli/reg/2024/1689/oj (дата обращения: 27.10.2026). — Текст : электронный.